

UNIVERSIDAD DE SANTIAGO DE
COMPOSTELA



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA

**Optimización en el acceso a nubes de
puntos de 3D mediante la utilización de
octrees y coordenadas polares**

Autor/a:

Manuel Ramallo Blanco

Tutores:

Francisco M. Fernández Rivera

Miguel Yermo García

Grado en Ingeniería Informática

Junio 2026

Trabajo de Fin de Grado presentado en la Escuela Técnica Superior de
Ingeniería de la Universidad de Santiago de Compostela para la obtención del
Grado en Ingeniería Informática



D. (Nome da titora ou do titor), Profesor/a do Departamento de Electrónica e Computación da Universidade de Santiago de Compostela, e **D. (Nome da cotirora ou do cotitor)**, Profesor/a do Departamento de Electrónica e Computación da Universidade de Santiago de Compostela,

INFORMAN:

Que a presente memoria, titulada (*Título do traballo*), presentada por **D. (Nome da autora ou do autor do traballo)** para superar os créditos correspondentes ao Traballo de Fin de Grao da titulación de Grao en Enxeñaría Informática, realizouse baixo nosa tutoría no Departamento de Electrónica e Computación da Universidade de Santiago de Compostela.

E para que así conste aos efectos oportunos, expiden o presente informe en Santiago de Compostela, a (Data):

Titor/a,

Cotitor/a,

Alumno/a,

(Nome do titor/a) (Nome do cotitor/a) (Nome do alumn/a)

Agradecimentos

Se se quiere pór algún agradecemento, este vai aquí.

Resumen

En este trabajo se describe y se presenta una solución de mejora de eficiencia temporal en el acceso a nubes de puntos 3D utilizando como estructura de datos *octrees* lineales. El estudio consiste en el reordenamiento espacial de puntos para tratar de explotar la capacidad de poda a la hora de encontrar vecindades. Se evalúan resultados temporales usando diferentes técnicas de reordenamiento, operando tanto con las coordenadas cartesianas como con las coordenadas polares de los puntos. Los resultados experimentales muestran un impacto positivo en la eficiencia temporal bajo determinadas circunstancias, a cambio de un gasto en memoria utilizada.

Indice

1. Introducción	1
2. Estado del arte del problema a abordar	5
3. Materiales	9
3.1. Equipos de cómputo y entorno de desarrollo	9
3.2. Marco teórico matemático	10
3.2.1. Coordenadas tridimensionales	10
3.2.2. Curvas de llenado de espacio	11
3.3. Algoritmos y estructuras de datos de partida	13
3.3.1. Octree lineal	13
3.3.2. Algoritmos de búsqueda	14
3.4. Conjuntos de datos empleados	15
4. Metodología	17
4.1. Fundamentos geométricos de la poda en nodos hoja	17
4.2. Primera Fase de Implementación: Selectores de rango polares y vectores de permutaciones	21
4.3. Análisis de Cuellos de Botella y Rediseño del Sistema	22
4.4. Segunda Fase de Implementación: Refactorización y Simplifica- ción de Modelos	24
4.5. Construcción de réplicas contiguas e integración en el flujo de búsqueda del Octree	25
5. Pruebas	29
5.1. Plan de Verificación y Corrección Global	29
5.2. Rendimiento de búsquedas de vecinos paralelas con centros alea- torios	29
5.3. Rendimiento de búsquedas de vecinos paralelas sobre toda la nube	33
6. Discusión de los resultados	37
7. Ejemplos (eliminar capítulo na versión final)	39
7.1. Un ejemplo de sección	39
7.1.1. Un ejemplo de subsección	39
7.1.2. Otro ejemplo de subsección	39
7.2. Ejemplos de figuras e cadros	40

7.3. Exemplos de referencias á bibliografía	40
7.4. Exemplos de enumeracións	40
8. Conclusións e posibles ampliacións	43
A. Manuais técnicos	45
B. Manuais de usuario	47
C. Licenza	49
Bibliografía	51

Índice de figuras

4.1. Funcionamiento de la poda en un espacio tridimensional usando ejes cartesianos.	18
4.2. Funcionamiento de la poda en un espacio tridimensional usando coordenadas esféricas/cilíndricas.	21
4.3. Distribución de claves óptimas por hoja en modo esférico sobre la nube <i>sg27_station_8</i>	23
4.4. Distribución de claves óptimas por hoja en modo cilíndrico sobre la nube <i>sg27_station_8</i>	24
4.5. Búsqueda base (Acceso secuencial).	26
4.6. Búsqueda reordenada (Acceso indexado).	26
4.7. Búsqueda base para el algoritmo <i>neighborsStruct</i>	27
5.1. Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios tomando diferentes radios en <i>5085_54320</i>	30
5.2. Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios tomando diferentes radios en <i>bildstein_station1</i>	31
5.3. Análisis del rendimiento temporal de hiperparámetros en las nubes de puntos <i>Mar18Train</i> y <i>Mar18Test</i>	32
5.4. Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios para diferentes radios en la nube <i>Mar18_Train</i>	33
5.5. Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios para diferentes radios en la nube <i>Mar18_Test</i>	33
5.6. Tiempos de ejecución de búsquedas completas variando el radio operativo sobre kernels esféricos y cúbicos para los datasets <i>5085_54320</i> (a) y <i>PNOA_2024_PNR_489-4672_NPC01</i> (b).	34
5.7. Tiempos de ejecución de búsquedas completas variando el radio operativo sobre kernels esféricos y cúbicos para los datasets <i>Mar18_train</i> (a) y <i>Paris_Luxembourg-6</i> (b).	35
5.8. Tiempos de ejecución de búsquedas completas variando el radio operativo sobre kernels esféricos y cúbicos para el dataset <i>bildstein_station1</i>	35
7.1. Esta é a figura de tal e cal.	40

Índice de cuadros

3.1. Nubes de puntos utilizadas en las evaluaciones experimentales. .	16
4.1. Porcentaje de puntos podados según el tipo de reordenamiento, geometría del kernel y radio de búsqueda (r) para las nubes analizadas.	23
7.1. Esta é a táboa de tal e cal.	40

Capítulo 1

Introducción

Las nubes de puntos 3D son una representación de una realidad, como un objeto o un terreno, mediante un conjunto de puntos en el espacio tridimensional, estando cada punto caracterizado por sus coordenadas X , Y y Z así como otras propiedades como el color o la intensidad. Entre las aplicaciones más importantes de la elaboración de estas nubes están la cartografía, la elaboración de modelos tridimensionales en CAD de piezas fabricadas, la metrología, la arqueología o la conducción autónoma. La tecnología predominante para la captura de estos puntos es la LiDAR (Light Detection And Ranging).

Una de las tareas más comunes al trabajar sobre nubes de puntos 3D es la búsqueda de vecindades alrededor de un punto dado. Una vecindad se define como el conjunto de puntos de puntos que están dentro de una figura geométrica determinada en el espacio con radio R y con el centro en el punto para el cual se están buscando vecinos. Esta combinación de figura geométrica de y radio se conoce como kernel de búsqueda. Otro método alternativo de análisis de vecindades es buscar los K puntos más cercanos al elemento de partida, técnica llamada KNN (*k nearest neighbors*).

Un gran problema a nivel de hardware de este proceso sobre nubes de puntos es que estos datos se recogen sin ningún tipo de estructura ni orden basado en localidad. Este fenómeno se junta con el hecho de que estas nubes pueden tener millones de puntos almacenados. Por eso, se necesitan métodos eficientes para acelerar este lento proceso de acceso a puntos cercanos.

Los *Octrees* y los *KDTrees* son estructuras jerárquicas ampliamente utilizadas para lidiar con este problema de ineficiencia. Consisten en dividir la nube de puntos de manera recursiva en zonas próximas en el espacio físico. Los *Octrees* son estructuras donde cada nodo se divide exactamente 8 hijos, dividiendo cada dimensión a la mitad (solo se usa en espacios tridimensionales). Los puntos pertenecen al nodo hoja que los contiene en su interior. Por otra parte, los *KDTrees* son árboles binarios que dividen cada nodo interno solamente según una dimensión. En cada nivel se elige un eje y se traza un hiperplano que divide a los puntos en dos nodos. De esta forma, este árbol es generalizable para cualquier espacio de dimensiones.

El rendimiento de estas estructuras depende directamente de la distribución de los puntos. Por eso es muy útil la aplicación técnicas de reordenamiento

espacial basadas en curvas de llenado de espacio (SFC). Las curvas de llenado son una representación mediante una línea continua de un cuadrado unidad bidimensional o, de forma general, un hipercubo N dimensional. En el caso de las nubes de puntos 3D nos interesa mapear los puntos tridimensionales a una representación unidimensional. El objetivo de la aplicación de curvas de llenado es mejorar la coherencia entre la localidad espacial de los puntos y su correspondiente localidad en memoria, con el fin de mejorar el rendimiento en esos accesos a memoria a la hora de calcular vecindades. Para lograr este reordenamiento, en la literatura destacan las curvas de Morton y las curvas de Hilbert, que implementan diferentes estrategias para proyectar los puntos en un índice lineal unidimensional.

En este trabajo se usará como base el modelo de *Octrees* propuesto por [1] donde se aplican las reordenaciones espaciales de Morton y Hilbert sobre diferentes implementaciones de *Octrees*, implementando tanto la estructura clásica basada en punteros como una versión lineal. Sobre esa implementación de algoritmo se tratará de optimizar todavía más el acceso a puntos vecinos. Para ello se empleará la técnica algorítmica de la poda.

Esta estrategia, de forma general, consiste en descartar o 'podar' regiones del espacio (nodos) o conjuntos de datos que matemáticamente se puede demostrar que no satisfacen las condiciones necesarias para ser solución. Su aplicación en este contexto es ser capaz de conocer *a priori* qué partes del *Octree* no pueden contener ningún vecino para una búsqueda dada. Esta técnica es, de hecho, el motivo por el que los *Octrees* (y los KDTrees) son estructuras ideales para almacenar nubes de puntos 3D, es muy sencillo podar nodos comprobando si sus límites están fuera del alcance del kernel de vecindad. Sin embargo, en este trabajo se explorará la poda a nivel de puntos dentro de un nodo, es decir, ser capaz de descartar puntos pertenecientes a un nodo hoja sin tener que evaluarlos individualmente. Para conseguir esta tarea se usarán reordenamientos de puntos a nivel de hoja siguiendo diversos criterios basados en coordenadas cartesianas con ejes X, Y, Z como definidores de los puntos, así como sistemas alternativos de representaciones tridimensionales: sistemas esféricos y cilíndricos, que se tratan de expansiones de las coordenadas polares.

Las coordenadas polares son un sistema de coordenadas bidimensional donde cada punto es caracterizado por una distancia radial y un ángulo con respecto del origen. Las coordenadas cilíndricas añaden el componente de la altura a las propiedades de un punto. Por otro lado, las coordenadas esféricas descomponen la posición en el radio tridimensional, el ángulo θ (coaltitud) y el ángulo φ (azimutal). En este contexto de nubes de puntos 3D almacenadas en *Octrees*, se tratará como el origen el centro geométrico de cada nodo.

Los reordenamientos en cuestión consisten en almacenar los puntos dentro de un nodo terminal de la estructura ordenados según alguna característica de las mencionadas. Así, se podrán calcular los límites de forma teórica para ese valor que puede tener un punto de forma que satisfaga la restricción de vecindad, dada una búsqueda con un kernel determinado.

Se estudiará el impacto en materia de eficiencia temporal de la aplicación de esta poda teórica de puntos en la implementación del *Octree* lineal propuesta en [1] con respecto a los algoritmos usados inicialmente. Finalmente, también

se analizará la escalabilidad de la técnica, paralelizando la búsqueda de vecinos.

Capítulo 2

Estado del arte del problema a abordar

El uso de Octrees como estructura de datos en la gestión y almacenamiento de nubes de puntos 3D es en la actualidad predominante a nivel global. Existen librerías de software libre ampliamente reconocidas que proporcionan soporte nativo tanto a estructuras Octrees como a KD-Trees para optimizar la indexación espacial.

Una de estas librerías es Open3D. Está escrita en C++ pero cuenta con interfaces estables para numerosos lenguajes, considerándose de facto el estándar en Python para la manipulación y visualización 3D. Open3D incluye métodos avanzados para el cálculo de distancias y la búsqueda de vecindad, dando soporte tanto a consultas basadas en kernels de radio como a la técnica de los K vecinos más cercanos (*K-Nearest Neighbors* o KNN).

Otro gigante en el manejo de nubes de puntos, considerada la librería de referencia absoluta en el entorno académico e industrial para el procesamiento de geometría 3D en C++, es PCL (*Point Cloud Library*) [ref pcl]. PCL proporciona un ecosistema masivo y modular que da soporte nativo a estructuras espaciales mediante las clases `pcl::Octree` y `pcl::KdTree`. El enfoque de PCL en sus Octrees tradicionales se basa en una estructura dinámica de punteros. Este diseño otorga una gran versatilidad para realizar modificaciones en tiempo real sobre la nube, como la inserción o eliminación dinámica de puntos y la detección de cambios espaciales. Por la contra, introduce una severa penalización en el rendimiento de la memoria. Esto se debe a la incoherencia entre la localidad espacial de los datos y su disposición física en el *heap* o montón, provocando constantes fallos de caché y saltos de punteros en el direccionamiento de la CPU durante los recorridos de búsqueda.

Un aspecto crítico que comparten tanto Open3D como PCL es que no implementan sus algoritmos de búsqueda desde cero, sino que integran internamente la librería FLANN (*Fast Library for Approximate Nearest Neighbors*) [ref flann]. FLANN es una biblioteca altamente optimizada para la búsqueda de vecinos más cercanos en espacios vectoriales multidimensionales. Si bien su principal característica es la capacidad de realizar búsquedas aproximadas (*Approximate Nearest Neighbor* o ANN) para mitigar la maldición de la dimensionalidad sa-

crificando un margen mínimo de precisión, en el contexto de búsquedas exactas por radio o kernel (como las evaluadas en este estudio) se configura en su modo exacto para operar como línea base de comparación directa.

Otras librerías relevantes con el mismo propósito, escritas también en C++, son PicoTree y NanoTree. PicoTree genera un KD-Tree integrado en un array contiguo mediante la indexación previa de los puntos, permitiendo búsquedas esféricas y de KNN altamente eficientes. Por su parte, NanoTree destaca por ser una implementación ligera y compacta optimizada para sistemas con restricciones de recursos.

Por otro lado, las curvas de llenado del espacio (SFC) son ampliamente aplicadas a estructuras jerárquicas para tareas de indexado o compresión. La integración de códigos de Morton en estructuras de Octree lineales ha sido una estrategia clave para mejorar la eficiencia en la ordenación de puntos. Un ejemplo de ello es el trabajo de Behley et al. con la librería *unibn* [2], donde se emplean estos códigos para reducir la necesidad de recorrer el árbol en toda su profundidad durante las búsquedas de vecindad, logrando superar el rendimiento de otras herramientas populares de la disciplina. Estos códigos son reconocidos por su simplicidad algorítmica y rapidez de cómputo a nivel de bits. Sin embargo, el otro gran algoritmo de SFC, las curvas de Hilbert, ha ganado una notable popularidad en la literatura reciente por garantizar una preservación superior de la localidad espacial, asegurando que si dos puntos son cercanos en el espacio tridimensional, mantendrán dicha proximidad en la proyección unidimensional de memoria de forma estricta.

No obstante, la aplicación directa de SFC en la búsqueda de vecindades en nubes de puntos 3D obtenidas con sensores LiDAR fue implementada originalmente en el trabajo de Díaz Viñambres et al. [1]. En dicha investigación se analiza en primer lugar una estructura Octree de punteros estándar construida mediante fragmentaciones recursivas. A pesar de que a esta estructura se le pueden aplicar reordenamientos según curvas de Morton o Hilbert para mejorar la cercanía en memoria de los puntos próximos, el enfoque clásico sigue adoleciendo del problema de los accesos indexados: cada transición entre nodos durante el recorrido implica saltar a una dirección del mapa de memoria que puede estar totalmente dispersa.

Por este motivo, los autores propusieron e implementaron una versión lineal del Octree, la cual almacena todos los puntos de la nube en un único vector contiguo, garantizando que todos los elementos pertenecientes a un mismo nodo hoja residan en posiciones físicas consecutivas del array. Adicionalmente, se introdujo un algoritmo de búsqueda por kernel geométrico que optimiza el proceso de recorrido: a diferencia del método clásico que desciende recursivamente verificando la mera intersección, este algoritmo identifica de forma temprana si el volumen del kernel contiene por completo el área que cubre el nodo (sea este interno o terminal). De cumplirse esta condición de inclusión total, el algoritmo realiza un volcado secuencial directo de todos los puntos del subárbol, abortando el descenso y acelerando drásticamente la consulta.

En la publicación de Díaz Viñambres et al. [1] se presentan resultados experimentales que demuestran la superioridad del Octree lineal (en sus variantes con reordenamiento de Morton y Hilbert) frente al Octree clásico de punteros.

Asimismo, se incluye un exhaustivo análisis comparativo de rendimiento frente a las soluciones de código abierto de referencia mencionadas anteriormente, tales como los módulos de PCL, PicoTree, NanoTree y la librería *unibn*. Bajo diferentes tipologías de datasets y variaciones en el radio del kernel de búsqueda, el Octree lineal reportó, de manera sistemática, los menores tiempos de ejecución computacional.

Sobre este escenario técnico se fundamenta el presente trabajo. En la práctica totalidad de las librerías del estado del arte existe un patrón de diseño común: las estructuras justifican su eficiencia basándose exclusivamente en la aplicación de la poda a nivel de nodos intermedios (ramas). Mediante funciones de solapamiento geométrico, se descartan de forma temprana subárboles completos cuyos volúmenes no intersectan con el kernel de consulta. Sin embargo, una vez que el algoritmo alcanza un nodo hoja válido, se ve obligado a evaluar la distancia de todos los puntos contenidos en él de manera individual y secuencial.

Hasta donde se tiene constancia en la literatura técnica y en las soluciones de código abierto analizadas, no existe ninguna implementación que acote el rango de puntos a evaluar mediante una poda matemática interna que actúe de forma nativa **en el interior del propio nodo hoja**.

Este cuello de botella constituye la principal motivación y el núcleo de la contribución de este trabajo. Al introducir funciones de cálculo de rango basadas en reordenamientos geométricos locales (tanto en sistemas cartesianos como esféricos y cilíndricos), este estudio permite aislar zonas y subrangos de puntos dentro de los nodos hoja. Esto cambia la concepción que se tenía sobre los nodos hoja, anteriormente pensados como unidades atómicas e indivisibles. Este enfoque persigue un incremento en el rendimiento temporal de la estructura del Octree lineal, motivada por la reducción del número de puntos evaluados como candidatos a vecinos. Como un extra, también busca aportar una mayor flexibilidad al diseño del software, permitiendo configurar tamaños de hoja más elevados sin penalizar el tiempo de cómputo por desbordamiento de búsquedas exhaustivas.

Capítulo 3

Materiales

En este capítulo se definirán y precisarán todas las herramientas, métodos, algoritmos y equipos que fueron empleados y tomados para la realización del estudio.

3.1. Equipos de cómputo y entorno de desarrollo

El entorno hardware en el que fueron desarrollados los experimentos de este proyecto es el Centro de Supercomputación de Galicia (CESGA). Este centro es un nodo de la Red Española de Supercomputación y datos (RES) y cuenta con una capacidad de computación total de 4.36 PetaFLOPS, estando compuesto por 357 nodos interconectados a través de una red Infiniband HDR.

Existen diferentes grupos de nodos con distintas especificaciones hardware. En concreto, estos experimentos fueron realizados en un nodo del grupo grupo (mirar en el cesga los nodos que se usaron y completar).

El entorno de software configurado y desplegado sobre esta arquitectura de hardware consta de las siguientes especificaciones:

- **Sistema Operativo:** Distribución Rocky Linux versión 8.4 (*Green Obsidian*), compatible con entornos Red Hat Enterprise Linux (RHEL).
- **Estándar de Lenguaje:** Se empleó el estándar **C++20**.
- **Compilador:** Las implementaciones fueron compiladas mediante la *GNU Compiler Collection* (GCC), cargando explícitamente el módulo `gcc/12.3.0`.
- **Directivas de Optimización y Extensiones Vectoriales:** Para la generación de los binarios ejecutables, se aplicó el nivel de optimización alta `-O2` junto con la macro `-DNDEBUG` para inhabilitar aserciones de depuración y maximizar el rendimiento. Adicionalmente, el sistema realiza un análisis de compatibilidad por hardware en el nodo de cómputo para activar de forma nativa las siguientes extensiones vectoriales:
 - `-mavx2` (*Advanced Vector Extensions 2*): Permite la vectorización de bucles mediante instrucciones SIMD en registros de 256 bits, procesando múltiples coordenadas de puntos 3D de forma simultánea.

- **-mbmi2** (*Bit Manipulation Instruction Set 2*): Introduce soporte directo por hardware para instrucciones avanzadas de manipulación de bits (como PDEP y PEXT).

Asimismo, se habilitó la optimización interprocedural o en tiempo de enlazado (LTO/IPO) a través de CMake, forzando a GCC a optimizar el proyecto de forma global y permitiendo la inserción en línea (*inlining*) de funciones entre diferentes archivos fuente.

- **Soporte de Paralelismo:** Se incluyó la API **OpenMP versión 4.5** encargada de la gestión y paralelización de hilos en memoria compartida. Se aplica en el código añadiendo directivas que definen el nivel de concurrencia en la inicialización de los bucles de búsqueda masiva sobre la estructura del Octree.

Aunque el descrito fue el entorno de ejecución real, se utilizó un entorno local de desarrollo para la programación y depuración del código fuente. Este entorno físico de soporte está constituido por una arquitectura de cómputo x86_64 basada en un procesador AMD Ryzen 7 6800H de 8 núcleos físicos y 16 hilos de ejecución concurrentes y un sistema de almacenamiento de memoria caché multinivel (L1, L2 y L3 de 512 KiB, 4 MiB y 16 MiB respectivamente).

Con el fin de compatibilizar el ecosistema de herramientas de desarrollo y mantener un entorno de terminal nativo unificado, el software se implementó sobre una capa de virtualización completa mediante el subsistema *Windows Subsystem for Linux* (WSL2) bajo el hipervisor de Microsoft. Sobre esta capa se desplegó una distribución del sistema operativo Linux, concretamente Ubuntu 24.04.3 LTS. Este entorno local sirvió como plataforma de validación para el diseño de los algoritmos, la verificación de la correcta aplicación de la poda y su integración con el código original antes de su posterior despliegue y compilación en los nodos de cómputo del CESGA.

3.2. Marco teórico matemático

3.2.1. Coordenadas tridimensionales

La base de este trabajo es optimizar el cálculo de distancias entre dos puntos en un espacio tridimensional. Concretamente, se trabaja con dos figuras geométricas (cubo y esfera) que envuelven los puntos de búsqueda. En ambas se hace uso de las 3 componentes cartesianas de un punto tridimensional en las comprobaciones de vecindad:

- **Kernel esférico:** Dos puntos son vecinos si la distancia d_{ij} entre el centro de búsqueda es menor al radio de búsqueda.

- Fórmula de la distancia:

$$d_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + (z_i - z_j)^2}$$

- Existe vecindad si se cumple: $d_{ij} < R_{\text{búsqueda}}$

- **Kernel cúbico:** Dos puntos son vecinos si la distancia entre los puntos para los tres ejes dimensionales por separado es menor al radio del cubo de búsqueda:

- Para un eje $k \in \{X, Y, Z\}$, la distancia d_{kij} se define como:

$$d_{kij} = |k_i - k_j|$$

- Existe vecindad si se cumple:

$$|x_i - x_j| \leq R \wedge |y_i - y_j| \leq R \wedge |z_i - z_j| \leq R$$

Para potenciar la poda o el descarte de puntos sin tener que realizar esta comprobación, se hará uso de otros sistemas de coordenadas tridimensionales existentes aparte de los cartesianos: el sistema esférico y el cilíndrico.

Ambos son extensiones del sistema bidimensional polar. En estas coordenadas un punto se define a través de dos magnitudes: un radio R y un ángulo θ sobre el origen. Para la proyección a 3 dimensiones, existe un sistema que añade un ángulo con respecto al plano y proyecta el valor del radio bidimensional a un radio tridimensional (coordenadas esféricas). Por otra parte, se puede incluir la componente Z , que le otorga la propiedad de altura a los puntos (coordenadas cilíndricas). La conversión de un punto a estos sistemas a partir de sus componentes se hace a través de las siguientes operaciones:

- **Coordenadas esféricas**

$$R = \sqrt{x^2 + y^2 + z^2}$$

$$\varphi = \arctan(y/x)$$

$$\theta = \arccos(z/R)$$

- **Coordenadas cilíndricas**

$$R = \sqrt{x^2 + y^2}$$

$$\varphi = \arctan(y/x)$$

$$Z = z$$

En el contexto concreto de los puntos dentro del Octree, se debe tener en cuenta que para poder operar a nivel de hoja se debe trasladar el origen de las coordenadas al centro del octree antes de realizar cualquier conversión u operación.

3.2.2. Curvas de llenado de espacio

Con el fin de optimizar la localidad espacial de los datos en memoria se introducen las curvas de llenado del espacio (SFC, *Space-Filling Curves*) como herramientas de ordenación. Se encargan de forzar que aquellos puntos próximos en el espacio tridimensional se almacenen de forma contigua en la zona de memoria reservada para la nube.

El proceso requiere la discretización previa del espacio continuo de la nube de puntos. Sea una nube de puntos $P \subset \mathbb{R}^3$, se define su caja contenedora o *bounding box* como la región semiabierta $B = [x_m, x_M) \times [y_m, y_M) \times [z_m, z_M)$, delimitada por sus esquinas inferiores y superiores. Fijando un nivel de subdivisión $L \in \mathbb{N}$ que determina una resolución de $N = 2^L$, se proyecta una rejilla discreta tridimensional $S_L = [0, N) \times [0, N) \times [0, N) \subset \mathbb{N}^3$, cuya cardinalidad total es de 2^{3L} celdas. Cada punto continuo $p = (x, y, z) \in P$ es trasladado, escalado y transformado en un elemento entero de la rejilla S_L mediante la aplicación de la función suelo.

En la implementación práctica de este estudio se fija un nivel máximo de subdivisión $L = 21$. Esto permite codificar la posición tridimensional de cada celda en un único identificador entero de 64 bits (restringiendo las coordenadas discretas originales a tipos de 32 bits), minimizando la probabilidad de colisión de múltiples puntos en una misma celda sin penalizar el rendimiento del sistema. Una curva de llenado del espacio de nivel l se define formalmente como la función biyectiva:

$$C : S_l \longrightarrow [0, 2^{3l})$$

Para el propósito de evaluar el impacto de la localidad en el rendimiento de los algoritmos de búsqueda, se consideran dos familias de curvas de llenado del espacio recursivas:

Código de Morton (Curva Z)

La curva de Morton, o curva Z, mapea las coordenadas tridimensionales discretas mediante el entrelazado directo de sus bits a nivel de registros de la CPU. Para un punto discretizado en la rejilla cuyas coordenadas binarias se expresan como $p = (x_0 \dots x_{L-1}, y_0 \dots y_{L-1}, z_0 \dots z_{L-1}) \in S_L$, su código de Morton se calcula de acuerdo con la ecuación:

$$C_M(x_0 \dots x_{L-1}, y_0 \dots y_{L-1}, z_0 \dots z_{L-1}) = x_0 y_0 z_0 x_1 y_1 z_1 \dots x_{L-1} y_{L-1} z_{L-1}$$

La ventaja computacional de esta estructura radica en la velocidad y eficiencia de su cálculo. Al tratarse de un mapeo posicional directo de bits, la codificación y decodificación puede implementarse a través de operaciones lógicas de enmascaramiento (*bitmasks*) y tablas de búsqueda (LUT, *Look-Up Tables*).

Curva de Hilbert

La curva de Hilbert es una curva de llenado continua que elimina los saltos espaciales característicos de la curva de Morton. El cálculo del código de Hilbert se realiza mediante un proceso iterativo por nivel de subdivisión en el cual, tras extraer los bits homólogos de cada dimensión, se aplica una secuencia de transformaciones geométricas y rotaciones que dependen del estado de orientación previo y del octante evaluado.

Matemáticamente, la propiedad fundamental de las curvas de Hilbert es su continuidad en el espacio, satisfaciendo la condición de vecindad de forma que

dos códigos consecutivos en el espacio unidimensional corresponden a celdas contiguas en el espacio tridimensional:

$$\|C^{-1}(i) - C^{-1}(i-1)\|_{\infty} = 1, \quad \forall i \in [1, 2^{3l-1}] \quad (3.1)$$

A nivel teórico, esta curva ofrece una localidad espacial superior a la de Morton. Sin embargo, carece de una correspondencia de bits directa y requiere un algoritmo iterativo más costoso para computar las matrices de rotación. Sin embargo, debe prevalecer la calidad sobre la complejidad a la hora de calcular los reordenamientos de las nubes de puntos, ya que es una operación que solo hace falta realizar una vez. Se puede ejecutar incluso en un programa separado y cargar las codificaciones cuando se inicialice la nube.

3.3. Algoritmos y estructuras de datos de partida

En este apartado se describirán las estructuras y explicarán los algoritmos de búsqueda que se usaron como base para el trabajo y que ya fueron mencionados: el Octree lineal implementado por [1] y sus algoritmos de búsqueda iterativos con poda a nivel de nodo.

3.3.1. Octree lineal

El proceso de construcción es un proceso iterativo, en el cual se parte de un nodo raíz que contiene toda la *bounding box* de la nube y divide repetidamente cada nodo terminal que contenga más de *maxLeaf* puntos, siendo este un valor paramétrico introducido por el programador. Una vez finalizada la construcción se obtiene un número N de nodos, separados en *nInternal* (número de nodos internos) y *nExternal* (número de nodos hoja). Todo el Octree está formado por el vector de puntos de la nube (reordenados mediante una curva de llenado y por lo tanto con una codificación asociada) junto con una serie de vectores persistentes que mapean las relaciones de descendencia entre nodos sin necesidad de usar punteros. Esta serie de vectores es la siguiente:

- `std::vector<uint32_t>offsets`

Tiene N elementos. La posición i almacena el índice de del primer hijo del nodo i . Todos los hijos de un nodo están en posiciones consecutivas. En caso de ser el nodo i un nodo hoja se cumple que `offsets[i] == 0`.

- `std::vector<std::pair<size_t, size_t>>internalRanges`

Tiene N elementos. En cada índice guarda las posiciones inicial y final de los puntos contenidos en él. Se usa para recorrer los puntos uno a uno en caso de llegar a una hoja que interseca con el kernel. Este es el punto de ineficiencia sobre el que se despliega este proyecto.

- `std::vector<Point>centers`

Cada elemento `centers[i]` contiene las coordenadas del centro geométrico del nodo i . También tiene N elementos.

- `std::vector<Vector>precomputedRadii`

Tiene L elementos siendo L la profundidad máxima encontrada en el Octree. Almacena para cada nivel de profundidad las dimensiones de los octantes.

Este formato presenta una serie de ventajas con respecto a un Octree de punteros. Se eliminan las indirecciones que provocan fallos caché y se asegura que toda la estructura esté en un grupo de bloques de memoria contiguos. Además, se conoce y se tiene acceso a los puntos contenidos por un octante, ya sea una hoja o no, y se consigue que esos puntos estén consecutivos en memoria gracias a la reordenación por SFC.

3.3.2. Algoritmos de búsqueda

A diferencia de las aproximaciones clásicas basadas en punteros, donde el recorrido del árbol requiere desreferenciar enlaces hacia nodos hijos dispersos en el montón o *heap*, el algoritmo optimizado implementado en este proyecto explota la geometría de los octantes y la contigüidad de los índices para discriminar bloques enteros de puntos.

El procedimiento general de búsqueda geométrica se rige por un esquema de recorrido recursivo sobre los nodos del árbol, evaluando la colisión espacial entre la caja del nodo actual y el volumen del kernel de consulta. El flujo algorítmico se define en los siguientes pasos:

1. **Evaluación de nodos tipo rama:** Si el nodo actual del octree es una rama (nodo interno), se computa la posición relativa de su volumen geométrico respecto a las fronteras del kernel de búsqueda:
 - a) **Inclusión completa:** Si el octante se encuentra totalmente contenido en el interior del kernel, se activa el mecanismo de rangos internos (*internal ranges*). Esto permite indexar y volcar de manera secuencial todos los puntos contenidos en dicho subárbol sin necesidad de descender más niveles ni evaluar individualmente sus elementos.
 - b) **Exclusión completa:** Si el octante se halla completamente fuera de los límites del kernel, se procede a la poda (*pruning*) inmediata de la rama, abortando esa vía de exploración.
 - c) **Intersección parcial:** Si el octante interseca con las fronteras del kernel pero no está contenido estrictamente en él, se continúa el recorrido recursivo descendiendo hacia sus nodos hijos.
2. **Evaluación de nodos tipo hoja:** Al alcanzar un nodo hoja que interseca parcialmente con el kernel, el algoritmo desciende al nivel atómico del dato, validando punto a punto mediante criterios geométricos si sus coordenadas pertenecen o no al interior del volumen de consulta.
3. **Retorno de resultados:** Tras concluir el recorrido, se consolida y devuelve la colección de índices de los puntos que se encuentran estrictamente contenidos en el espacio delimitado por el kernel.

Para la materialización y almacenamiento de estos índices resultantes, se han desarrollado dos variantes algorítmicas diferenciadas por su estrategia de gestión de memoria y estructuración de datos: **neighborsPrune** y **neighborsStruct**.

Algoritmo **neighborsPrune**

Esta variante implementa una estrategia de inserción directa y plana. Cuando el algoritmo identifica puntos válidos en el interior del kernel (ya sea mediante la evaluación individual en hojas o por la inclusión completa de una rama), añade cada índice de punto vecino como un elemento independiente y separado dentro de un vector dinámico estándar (`std::vector<size_t>`). Si bien el coste de inserción es secuencial, esta aproximación puede resultar innecesaria en nubes densas, donde se insertan numerosos puntos consecutivos.

Algoritmo **neighborsStruct**

Con el objetivo de mitigar el coste de inserción masiva de elementos individuales, la variante **neighborsStruct** aprovecha la contigüidad física de los datos reordenados en memoria. En lugar de almacenar elementos aislados, define una estructura de rangos indexados mediante el tipo:

```
std::vector<std::pair<size_t, size_t>> ranges;
```

Bajo este esquema, cuando una secuencia de puntos consecutivos en memoria pertenece de forma unánime al kernel de consulta (caso seguro al incluir ramas totalmente contenidas), el algoritmo compacta la información realizando únicamente dos operaciones de inserción por bloque: el índice de la posición inicial y el índice de la posición final del rango. Esta técnica reduce drásticamente el espacio de almacenamiento temporal, minimiza las escrituras en memoria caché, optimizando la velocidad del algoritmo.

3.4. Conjuntos de datos empleados

Las nubes de puntos 3D que fueron usadas para evaluar el rendimiento del algoritmo de poda a nivel de hoja vienen descritos a continuación, en el Cuadro 3.1. Las nubes están almacenadas en archivos binarios estándar con extensión **.LAS**. Este formato contiene los datos espaciales tridimensionales aparte de campos opcionales con más propiedades de los puntos, como intensidad, color o clasificaciones de terreno.

La selección de nubes de puntos se realizó tratando de buscar la máxima variedad posible: se mezclan conjuntos de datos de baja y alta densidad, así como nubes extraídas con sensores LiDAR tanto aéreos como terrestres y por último variedad en el número total de puntos contenidos.

Nube	nPuntos	Dataset	Descripción
<i>bildstein_station1_xyz_intensity_rgb</i>	29.6 M	Semantic3D	Escaneo LiDAR terrestre y urbano desde una posición estática. Nubes muy densas.
<i>sg27_intensity_rgb</i>	73.9 M		
<i>5085_54320.las</i>	14.4 M	DALES	LiDAR aéreo obtenido desde aeronaves. El conjunto se divide en celdas disjuntas.
<i>5095_54440.las</i>	11.7 M		
<i>Lille_0</i>	10.0 M	Paris-Lille 3D	Sensor LiDAR de tipo Mobile Laser Scanning (MLS) instalado sobre un vehículo que mapea dos calles urbanas en París.
<i>Paris_Luxembourg_6</i>	10.0 M		
<i>PNOA_2024_PNR_489-4672_NPC01</i>	18.5 M	PNOA-II	Cobertura del territorio español mediante LiDAR aéreo. Presenta una densidad baja, cubriendo grandes extensiones.
<i>Mar18_train</i>	59.4 M	Hessigheim 3D	Dataset aéreo de alta resolución capturado mediante UAV (<i>Unmanned Aerial Vehicle</i>) sobre el pueblo de Hessigheim.
<i>Mar18_test</i>	51.7 M		

Cuadro 3.1: Nubes de puntos utilizadas en las evaluaciones experimentales.

Capítulo 4

Metodología

En este capítulo se expone detalladamente el proceso de diseño, implementación y optimización incremental de los nuevos algoritmos de poda geométrica a nivel de nodo hoja sobre la estructura del Octree lineal. El objetivo metodológico fundamental de este estudio es romper el carácter indivisible de los nodos hoja tradicionales, acotando el espacio de búsqueda lineal mediante la aplicación de criterios analíticos basados en proyecciones cartesianas, esféricas y cilíndricas.

A diferencia de un desarrollo estático, la metodología de este proyecto se ha concebido como un proceso iterativo guiado por el rendimiento. A lo largo de las siguientes secciones se describirán las técnicas utilizadas a lo largo de la evolución del software. Se partió de un modelo teórico inicial enfocado en la máxima restricción geométrica y el ahorro de memoria, pasando por el análisis de cuellos de botella computacionales hasta converger en una solución de alta localidad espacial y bajo coste de computación.

4.1. Fundamentos geométricos de la poda en nodos hoja

En esta sección se explica cómo se realiza exactamente la poda para descartar puntos dentro de hojas conflictivas. Como ya se ha visto anteriormente, es sencillo conseguir los valores de coordenadas esféricas o cilíndricas a partir de coordenadas cartesianas tridimensionales. Para cada propiedad que las define, se puede delimitar unos valores máximo y mínimo que un punto puede tener para que, dado un kernel de búsqueda definido, pueda estar dentro de ese kernel de vecindad, de forma que si no tiene un valor fuera de ese intervalo se descartará automáticamente. Lo interesante de esta cuestión es no tener que calcular esos valores uno a uno, eso es exactamente lo que hacen los algoritmos originales. Lo que convierte este cálculo en un algoritmo eficiente es ordenar los puntos, de forma independiente en cada hoja, según cada una de esas claves en la inicialización de la estructura. De esta forma, basta con encontrar los puntos que suponen el límite inferior y superior del intervalo y se tiene automáticamente el conjunto de puntos a evaluar, descartando el resto. La eficiencia de esta técnica depende de dos factores fundamentales: la efectividad directa de

la poda, es decir, el porcentaje de puntos descartados, que debe ser lo mayor posible; y la reducción de la sobrecarga en el cálculo, debiendo evitar que el coste de definir los índices sobre los que buscar no supere el coste de rechazar los puntos descartados uno a uno, tal y como se estaba haciendo.

A continuación se detalla como se definen los valores máximos y mínimos para cada propiedad posible del punto. Una consideración a tener es que este proceso no es único de las coordenadas polares, se puede tomar la misma técnica con los valores de los ejes X, Y, Z. De hecho, es *a priori* una buena opción ya que se evitan las operaciones de transformación de sistema de coordenadas, por lo que es una estrategia que se tendrá en cuenta. En la Figura 4.1 se puede ver una simulación gráfica de cómo se realiza la poda en el espacio de 3 dimensiones, en este caso usando el eje X para la poda. El cubo negro representa la hoja del Octree mientras que el azul representa el kernel de búsqueda cúbico, con el punto de búsqueda en su centro. La zona cortada por el hiperplano que queda en el interior de la hoja es la única zona donde puede haber vecinos, sea la distribución que sea.




Figura 4.1: Funcionamiento de la poda en un espacio tridimensional usando ejes cartesianos.

El cálculo matemático de los límites de búsqueda es directo si se traslada el origen al centro de la hoja del Octree. Dado un punto de búsqueda $Q = (q_x, q_y, q_z)$ y un radio de búsqueda r_k para cada eje $k \in \{X, Y, Z\}$ (ya sea una esfera o un cubo), un punto cualquiera $P = (p_x, p_y, p_z)$ perteneciente a dicha hoja se considera un candidato potencial a vecino si y solo si sus coordenadas satisfacen la siguiente condición para el componente $k \in \{X, Y, Z\}$ que está siendo estudiado:

$$p_k \in [q_k - r_k, \quad q_k + r_k]$$

Lo cual equivale a la restricción de vecindario por componentes dada por el valor absoluto:

$$|p_k - q_k| \leq r_k$$

4.1. FUNDAMENTOS GEOMÉTRICOS DE LA PODA EN NODOS HOJA19

Aquí se debe realizar un apunte. La restricción real para que un punto de búsqueda $Q = (q_x, q_y, q_z)$ sea vecino es la agregación de la restricción anterior para todas sus componentes:

$$\forall k \in \{X, Y, Z\}, \quad p_k \in [q_k - r_k, \quad q_k + r_k]$$

Sin embargo, de esta forma no se pueden hacer ordenaciones y habría que hacer intersecciones de rangos para hallar los puntos candidatos. Esto eliminaría el objetivo de la optimización, evitar tener que comprobar puntos uno a uno, además de eliminar la localidad y suponer una sobrecarga demasiado grande. Por estos motivos se trabajará con las propiedades de los puntos de forma separada para la extracción de rangos.

De forma análoga, es posible determinar analíticamente los límites inferiores y superiores para las variables de los sistemas de coordenadas alternativos. Dado un punto de búsqueda $Q = (q_x, q_y, q_z)$ y un radio de consulta r , se debe realizar una consideración previa cuando se emplean entornos volumétricos ortogonales: en el caso del kernel cúbico, para garantizar que ningún candidato potencial quede excluido y no sobreestimar las condiciones de vecindad, se toma como radio efectivo el de la esfera mínima circunscrita que lo envuelve completamente, el cual se define formalmente como $r_{\text{efectivo}} = r\sqrt{3}$.

En el marco del sistema de **coordenadas esféricas**, la evaluación del ángulo azimutal φ (cuyo dominio se restringe al intervalo $[-\pi, \pi)$) se estructura a partir de la proyección del punto de búsqueda en el plano xy . Se define la distancia de la *query* al origen como $\rho_q = \sqrt{q_x^2 + q_y^2}$. El ángulo azimutal del punto de búsqueda se calcula mediante la función arcotangente de dos parámetros como $\varphi_q = \text{atan2}(q_y, q_x)$.

Geométricamente, la máxima desviación angular posible que puede tener un vecino a una distancia horizontal ρ_q viene acotada por las tangentes a la esfera de búsqueda. Por lo tanto, el intervalo de tolerancia angular dentro del cual debe encontrarse un punto para optar a ser vecino se define como:

$$\Phi = [\varphi_q - \Delta\varphi, \quad \varphi_q + \Delta\varphi]$$

Donde el semiángulo de apertura $\Delta\varphi$ se deduce de la relación trigonométrica:

$$\Delta\varphi = \arcsin\left(\frac{r}{\rho_q}\right)$$

Continuando con el sistema de **coordenadas esféricas**, la segunda componente angular a evaluar corresponde al ángulo de coaltitud o ángulo polar θ , cuyo dominio físico se restringe al intervalo $[0, \pi]$. Este ángulo describe la desviación respecto al eje de ordenadas Z y se calcula analíticamente a partir de la distancia euclídea tridimensional al origen, definida como $r_q = \sqrt{q_x^2 + q_y^2 + q_z^2}$, mediante la relación:

$$\theta_q = \arccos\left(\frac{q_z}{r_q}\right)$$

De manera homóloga al análisis azimutal, la dispersión angular máxima para los candidatos a vecinos en esta dimensión se encuentra acotada por el

contorno de la esfera de búsqueda de radio r . Por consiguiente, el intervalo de aceptación para el ángulo polar se establece como:

$$\Theta = [\theta_q - \Delta\theta, \quad \theta_q + \Delta\theta]$$

Donde la apertura angular crítica $\Delta\theta$ se deriva directamente como:

$$\Delta\theta = \arcsin\left(\frac{r}{r_q}\right)$$

No obstante, existe una condición geométrica singular para estas dos componentes angulares que hace automáticamente nula la poda y permite mitigar el coste computacional al eludir el cálculo de funciones trigonométricas inversas, de alto coste en CPU. La estrategia de poda es estéril si se satisface la relación:

$$r \geq r_q \quad (\text{o } r \geq \rho_q \text{ en el plano } xy)$$

La naturaleza de esta restricción radica en que, si el radio de consulta es mayor o igual a la distancia del punto de búsqueda al origen, el volumen del kernel contiene de forma implícita dicho origen. En consecuencia, el espacio de búsqueda abarca todas las direcciones del espacio y por lo tanto todo el dominio de valores angulares, imposibilitando cualquier restricción angular efectiva.

Por último, la cota asociada a la componente radial tridimensional r_p de cualquier punto candidato P para el filtrado en esféricas es directa, obligando al punto a posicionarse dentro del rango de distancias determinado por:

$$R_{\text{esférico}} = [r_q - r, \quad r_q + r]$$

En contraposición, cuando el análisis se reduce a un sistema de **coordenadas cilíndricas**, la componente radial se evalúa de forma bidimensional. La distancia proyectada de la *query* se define como $\rho_q = \sqrt{q_x^2 + q_y^2}$, y el criterio de vecindad para la magnitud del radio cilíndrico ρ_p de los puntos de la hoja se simplifica al intervalo:

$$R_{\text{cilíndrico}} = [\rho_q - r, \quad \rho_q + r]$$

En la Figura 4.2 se ilustra un ejemplo de mecanismo de poda en el espacio tridimensional, empleando en este caso el ángulo azimutal φ . Como se observa, el algoritmo traza dos hiperplanos orientados según los límites angulares calculados, descartando inmediatamente cualquier punto cuyos límites geométricos queden completamente fuera del sector angular Φ .

4.2. PRIMERA FASE DE IMPLEMENTACIÓN: SELECTORES DE RANGO POLARES Y VECTORIALES




Figura 4.2: Funcionamiento de la poda en un espacio tridimensional usando coordenadas esféricas/cilíndricas.

4.2. Primera Fase de Implementación: Selectores de rango polares y vectores de permutaciones

Las decisiones de diseño iniciales se caracterizaron por buscar un equilibrio entre la minimización de la sobrecarga en memoria introducida y en maximizar la cuota de puntos podados. Un trabajo inicial que hubo que realizar fue exponer una serie de funciones en la clase del Octree lineal para poder operar a nivel de hoja con comodidad. Estas funciones dan acceso a una serie de vectores que contienen los centros de las hojas y pares de índices que indican el inicio y el final de los puntos de la hoja en la estructura original del Octree, así como una función que devuelve el número total de hojas. Una vez integradas estas funciones preliminares, la primera parte de la implementación es construir el reordenamiento de puntos a nivel de hoja. Esto se hace a la hora de inicializar la estructura y las operaciones solo se llevan a cabo una vez al cargar la nube de puntos, por lo que la eficiencia temporal no es una gran preocupación. Sí lo puede ser, sin embargo, el consumo de memoria. Por eso la primera aproximación fue la de crear vectores de permutaciones. La utilidad de estos es almacenar, dentro de una hoja, el índice global de los puntos en orden creciente siguiendo una clave concreta de las analizadas en la sección anterior. Para ordenar cada vector se usó la función `std::sort`, con complejidad temporal $\mathcal{O}(N \log(N))$. Así, para acceder, por ejemplo, al punto con el radio esférico menor de la hoja i bastaría con acceder a `points[permsRadius[i][0]]` siendo `points` el array de puntos originales. El beneficio de este método es que cada elemento es un `size_t` y ocupa 8 bytes frente a los 32 bytes que ocupa un objeto de la clase `Point`. Por otro lado, se diseñó la técnica de selección de rango. Esta funcionalidad está pensada para ser ejecutada una vez por cada ocasión en la que se llegue a una hoja conflictiva durante una búsqueda, por lo que se ejecutará miles de veces por ejecución y será trascendental buscar la máxima eficiencia temporal, a la vez que se debe conseguir una poda lo mejor posible. Este equilibrio a buscar es el factor más decisivo a la hora de enfocar el diseño de esta función.

Este módulo debe devolver los rangos mínimo y máximo para examinar de la hoja que se está evaluando. En ella se hacen los cálculos matemáticos descritos en la anterior sección para conseguir los límites numéricos y a continuación se lleva a cabo una búsqueda binaria sobre los puntos reordenados de la hoja para transformar los valores en el intervalo de índices correspondiente, por lo que la complejidad del selector es $\mathcal{O}(\log_2 N)$, aparte de la sobrecarga introducida por los cálculos matemáticos.

Se implementaron de salida dos modos de reordenamiento independientes, uno usando las características de un punto según coordenadas esféricas y otro según coordenadas cilíndricas. Se hizo de esta manera porque no tiene sentido mezclar claves de ambos sistemas en una única búsqueda: Las podas que se pueden realizar con coordenadas esféricas son por definición más restrictivas que las que se pueden hacer con el sistema cilíndrico. La poda por el ángulo φ es directamente la misma. La poda que el ángulo θ lleva a cabo se define por la posición en el eje Z del punto de búsqueda, pero es más estricta que podar directamente en base al valor de Z (la ventaja del sistema cilíndrico aquí es que puede podar casos en los que el kernel cubra el centro). Por último, el radio tridimensional es más estricto que el radio en el plano XY. En conclusión, las coordenadas esféricas consiguen un rango más estricto mientras que las coordenadas cilíndricas son algo menos costosas computacionalmente. Esto hace que no tenga sentido mezclar los sistemas en las búsquedas, y proponen una comparativa interesante a estudiar entre los dos modos. Se añadió como parámetro de entrada el parámetro `--local-reorder`, que podía tomar uno o varios valores de entre los siguientes: `[none,spherical,cylindrical]` Una vez tomada la decisión de separar las reordenaciones esféricas y cilíndricas se definieron los detalles de la estrategia en la selección de rango, que fue la siguiente:

1. Se investigan las tres posibles reordenaciones para el sistema de coordenadas elegido. Para cada clave:
 - a) Se calculan los valores límite tal y como se expuso anteriormente.
 - b) Se traducen los valores a índices mediante la búsqueda binaria.
2. Al finalizar el bucle, se comprueba qué clave deja un rango más pequeño a examinar.
3. Se devuelve un código que se asocia con el reordenamiento elegido, los índices mínimo y máximo y el vector de permutaciones correspondiente.

4.3. Análisis de Cuellos de Botella y Rediseño del Sistema

Una vez terminada la implementación e integración de la versión base de la poda, se llevaron a cabo unas pruebas preliminares para poder tener una primera referencia de su desempeño. Los resultados fueron negativos para diferentes tipos de nubes, por lo que hubo que pasar por un proceso de análisis exhaustivo para encontrar las causas y soluciones del mal rendimiento de la implementación de las podas con respecto a los algoritmos base. Para conocer la

4.3. ANÁLISIS DE CUELLOS DE BOTELLA Y REDISEÑO DEL SISTEMA23

efectividad de la poda en sí se introdujo el modo de debug en el programa, con el que se exportan a un archivo información de cada hoja conflictiva a la que se llega. Se imprime qué modo de reordenamiento se está usando (cilíndrico o esférico), qué clave concreta fue mejor y por tanto se usó en esa hoja, el número de puntos de la hoja y el número de puntos restantes después de la poda. Con esta información se llevó a cabo un estudio de la efectividad de la poda sobre un pequeño conjunto de nubes que dio lugar a los resultados mostrados en el Cuadro ???. También se analizó el éxito de cada clave de reordenamiento, cuyos resultados se recogieron en las Figuras 4.3 y 4.4.

Reordenamiento	Radio (r)	Paris-Lille		sg_27_station		Lille_0	
		Cubo	Esfera	Cubo	Esfera	Cubo	Esfera
Cilíndrico	0.5	13.8 %	37.0 %	39.2 %	51.9 %	5.2 %	28.2 %
	1.0	8.5 %	28.8 %	6.4 %	33.3 %	6.1 %	28.4 %
	2.0	7.0 %	26.0 %	3.6 %	31.7 %	12.4 %	33.5 %
	3.0	6.7 %	23.9 %	2.4 %	32.2 %	17.2 %	39.1 %
Esférico	0.5	9.3 %	38.7 %	22.3 %	48.6 %	2.8 %	32.3 %
	1.0	3.9 %	32.6 %	6.2 %	36.2 %	3.8 %	32.4 %
	2.0	2.6 %	31.4 %	3.5 %	33.8 %	9.2 %	35.5 %
	3.0	1.4 %	30.8 %	2.3 %	34.2 %	13.8 %	40.1 %

Cuadro 4.1: Porcentaje de puntos podados según el tipo de reordenamiento, geometría del kernel y radio de búsqueda (r) para las nubes analizadas.




Figura 4.3: Distribución de claves óptimas por hoja en modo esférico sobre la nube sg27_station_8




Figura 4.4: Distribución de claves óptimas por hoja en modo cilíndrico sobre la nube sg27_station_8

De estos datos se pueden extraer varios aprendizajes. En primer lugar, las podas con kernel cúbico tienen una efectividad prácticamente nula debido a la sobreestimación que hay que realizar, lo cual probablemente provoque que para la mayoría de hojas el kernel cubra el centro o incluso la hoja entera. Ese porcentaje que se ahorra, de entre el 5 y el 10 % de las hojas, no compensa para nada la sobrecarga introducida y el gasto en memoria. También se aprecia un comportamiento a tener en cuenta de aquí en adelante, y es que cuánto más pequeño sea el radio, más efectiva será la poda de forma general. Esto ocurre así porque la sección angular que cubre una esfera, estando a la misma distancia siempre del centro, es proporcional al tamaño de esta, y esferas pequeñas se pueden encerrar en regiones muy estrechas. Por último, en las Figuras 4.3 y 4.4 hay un patrón muy claro. La clave que mejor funciona con mucha diferencia es el ordenamiento por ángulo φ , seguido de lejos por la coordenada Z .

Este estado de conocimiento dio pie a una serie de optimizaciones y rediseños que fueron aplicados sobre los algoritmos.

4.4. Segunda Fase de Implementación: Refactorización y Simplificación de Modelos

Tras analizar los resultados preliminares, se tomaron una serie de cambios en el enfoque de las podas. Los principales problemas a arreglar eran la ineffectividad con el kernel cúbico y la excesiva sobrecarga en proporción a la magnitud de hojas podadas.

Dada la dominancia del ángulo φ para los reordenamientos, se decidió usar solo esa clave de aquí en adelante. Esta decisión tiene una desventaja, y es que se quedarán sin podar hojas que quizás con el ángulo de coaltitud o el radio sí descartarían puntos. Pero las ventajas son un gran ahorro en memoria, teniendo en cuenta que también se eliminan los dos modos separados de coordenadas esféricas y cilíndricas, y un gran ahorro en la sobrecarga de la selección de

4.5. CONSTRUCCIÓN DE RÉPLICAS CONTIGUAS E INTEGRACIÓN EN EL FLUJO DE BÚSQUEDA

rangos. El funcionamiento de la selección de rango en las búsquedas ahora simplemente consiste en calcular los valores límites angulares en el dominio $[-\pi, \pi)$, realizar la búsqueda binaria para encontrar el rango de puntos en la hoja y devolver el rango junto con el vector de permutaciones necesario para efectuar la búsqueda. Cabe destacar, eso sí, un condicional implementado a mayores. El dominio de valores es circular, es decir, que un kernel puede soportar un rango del tipo $[x, \pi), [-\pi, y]$. Se incluyó esta posibilidad devolviendo dos pares de índices e incluyendo un nuevo condicional en los algoritmos de búsqueda, que recorren el segundo intervalo de puntos en caso de ser necesario.

En este punto se tomó la decisión de implementar otro tipo de reordenamiento, de forma que hubiese dos modos independientes de nuevo. En este caso, se usarían los valores de los ejes de coordenadas X, Y, Z para hacer los reordenamientos a nivel de hoja, de forma que habría 3 posibles claves, al igual que en el primer algoritmo propuesto. Sin embargo, en este caso hay una serie de ventajas que hacen esta implementación mucho más atractiva. Para empezar, los valores cartesianos ya están definidos en los puntos, no hay que hacer cálculos a mayores para transformar las coordenadas y posteriormente ordenar los puntos. Además, el cálculo de límites es extremadamente rápido. Tal y como se detalló en la sección 4.1, no es más que una suma/resta. A mayores, se espera que este formato arregle el problema presente en los resultados de poda obtenidos de la dependencia al tamaño del radio. Los ejes cartesianos pueden podar cualquier sección de la hoja, mientras que el efecto del ángulo azimutal se anula cuando el kernel sobrepasa el centro de la hoja. Por último, hay una nueva optimización sobre la selección de rango posible para este caso. El cálculo de la región entre los valores límites es trivial y nada costosa, por lo que se puede usar como referencia para determinar cuál es el eje que más puntos desecha y se elimina la necesidad de ejecutar las búsquedas binarias por partida triple. Dado que no se asegura una distribución uniforme de los puntos, este método no asegura que se esté escogiendo la clave óptima siempre, pero es una aproximación muy eficiente temporalmente y no se espera una pérdida significativa en efectividad de poda.

Por tanto, se llevo a cabo la refactorización, unión y simplificación del algoritmo de poda basado en coordenadas esféricas/cilíndricas (modo de reordenamiento polar de aquí en adelante) y se implementó el modo basado en coordenadas ordenadas (modo cartesiano de aquí en adelante). La implementación de las funciones de selección de rango y algoritmos de búsqueda se hizo en funciones separadas para aumentar el desacoplamiento y evitar la ejecución de condicionales en tiempos de ejecución.

4.5. Construcción de réplicas contiguas e integración en el flujo de búsqueda del Octree

En paralelo a la implementación de los nuevos modos polar y cartesiano, se analizó y diseñó otra optimización temporal, basada esta vez en la localidad de memoria durante el bucle de búsqueda. Hasta ahora, las reordenaciones se estaban haciendo mediante vectores de permutaciones, lo que provocaba accesos

a memoria extra en relación al algoritmo base. En las Figuras 4.5 y 4.6 vemos una comparación entre el bucle base y el modificado para poder recorrer el intervalo podado mediante indirecciones para el algoritmo `neighborsPrune`:

Require:

leafStart, leafEnd, points, k

Ensure: *ptsInside*

```

1: for i = leafStart to leafEnd - 1
  do
2:   if k.isInside(points[i]) then
3:     ptsInside.push_back(i)
4:   end if
5: end for

```

Figura 4.5: Búsqueda base (Acceso secuencial).

Require:

rangeStart, rangeEnd, points, perms, k

Ensure: *ptsInside*

```

1: for i = rangeStart to rangeEnd - 1
  do
2:   if k.isInside(points[perms[i]])
    then
3:     ptsInside.push_back(perms[i])
4:   end if
5: end for

```

Figura 4.6: Búsqueda reordenada (Acceso indexado).

El objetivo es poder aplicar el bucle 4.5 a la vez que las podas a nivel de hoja. Para conseguirlo, es necesario hacer una réplica del vector de puntos de forma que cada hoja empiece en el mismo índice, para mantener la coherencia con la parte exterior del algoritmo, pero estando los puntos reordenados a nivel de hoja. Esta decisión introduce un gasto mayor en memoria, pero se asume teniendo en cuenta que el objetivo principal del trabajo es encontrar eficiencia temporal y que hasta ahora los resultados no habían sido positivos, además de que con la simplificación de los algoritmos de selección de rangos ya se hizo un ahorro de memoria sobre la versión inicialmente planteada. De esta forma, después de la construcción de la estructura, se intercambia la creación de los vectores persistentes de permutaciones por duplicaciones de `points` con reordenamientos incluidos a nivel de hoja.

En el caso del modo polar, este cambio funcionó de manera correcta. El formato del bucle de búsqueda es el mismo. Los índices guardados en el almacén de vecinos `ptsInside` hacen referencia al vector de reordenamiento polar `polarPoints`. La única diferencia es que en este modo se incluye el bucle condicional sobre el segundo rango que se recorrerá en caso de existir, tal y como se expuso en la sección 4.4.

Sin embargo, en el modo cartesiano la búsqueda no es tan sencilla. Se están mezclando tres vectores de reordenamiento diferentes en diferentes hojas de la misma búsqueda. Por tanto hay que recuperar un puntero al inicio de la hoja de uno de ellos dependiendo de cuál produjese la mejor poda. Aparte de esa pequeña sobrecarga, hay un problema mayor a la hora de incluir los índices en el almacén de vecinos. No se pueden añadir mediante la forma `push_back(i)` porque una vez terminada la búsqueda, a la hora de acceder y reconstruir los vecinos, sería imposible saber a qué vector apunta cada índice.

La solución que se adoptó fue usar el campo `id` existente en la estructura `Point`. En ella, a la hora de construir los vectores reordenados, se incluyeron las

4.5. CONSTRUCCIÓN DE RÉPLICAS CONTIGUAS E INTEGRACIÓN EN EL FLUJO DE BÚSQUEDA

posiciones originales de cada punto. De esta forma, durante el bucle se insertan los puntos accediendo a la función `id()` del punto, una función *getter* del campo. La ineficiencia de este acceso extra existe, pero teniendo en cuenta que es una función *inline* y que el objeto `Point` fue accedido justo antes y debería estar en caché, es la mejor solución posible ante el problema planteado.

Esta explicación, sin embargo, solo aplica al algoritmo `neighborsPrune`. El algoritmo `neighborsStruct` incluye una forma de almacenado de vecinos basada en pares de índices, como se aprecia en la siguiente Figura 4.7.

Require: *leafStart, leafEnd, points, k*

Ensure: *ptsInside*

```
1: rangeStart  $\leftarrow$  leafStart
2: for i = leafStart to leafEnd - 1 do
3:   if  $\neg k.isInside(points[i])$  then
4:     if rangeStart < i then
5:       result.addRange(rangeStart, i)
6:     end if
7:     rangeStart  $\leftarrow$  i + 1
8:   end if
9: end for
```

Figura 4.7: Búsqueda base para el algoritmo `neighborsStruct`.

Nuevamente, el modo polar aplica exactamente la misma lógica que las búsquedas originales, por lo que la adaptación a este algoritmo es trivial. Por otra parte, hasta donde se analizó, no es posible la adaptación del modo cartesiano. Los rangos en un vector de reordenamiento concreto se corresponden con puntos aleatoriamente distribuidos en el vector `Points`, por lo que es imposible hacer una inserción de vecinos mediante rangos.

Para terminar el capítulo de implementación, cabe mencionar que se introdujo un parámetro personalizable `threshold` al programa. Su función es impedir que la sobrecarga de selecciones de rango sea mayor al tiempo ahorrado en el bucle de búsqueda. Por tanto, cualquier hoja con $N_{puntos} < threshold$ será recorrida de forma secuencial.

Capítulo 5

Pruebas

En este capítulo se expondrán los experimentos ejecutados en el CESGA y los resultados obtenidos. El experimento se divide en dos secciones: el análisis principal, el de tiempos de ejecución, y un análisis de escalabilidad de paralelización. Los experimentos de tiempos de ejecución se dividen a su vez en búsquedas de subconjuntos con centros aleatorios y en búsquedas de nubes completas.

5.1. Plan de Verificación y Corrección Global

Como paso previo e indispensable al análisis de rendimiento, se diseñó un script de pruebas unitarias automatizadas para verificar la fidelidad de los nuevos algoritmos orientados a la poda en nodos hoja. Para cada una de las configuraciones evaluadas en este capítulo, se contrastaron los resultados de vecindad devueltos por las variantes optimizadas frente a los resultados reportados por la implementación base del Octree lineal clásico. La verificación produjo una coincidencia del 100 %, por tanto se pasó al estudio de los resultados temporales, con la garantía de que en las podas se descartan únicamente regiones del espacio geométrico disjuntas al kernel.

5.2. Rendimiento de búsquedas de vecinos paralelas con centros aleatorios

Estos experimentos exploran la eficiencia temporal en la ejecución de un lote de 10.000 consultas espaciales con centros distribuidos aleatoriamente. Cada configuración se repitió 5 veces, tomando como métrica el tiempo medio de ejecución. Cabe destacar que se empleó una paralelización a escala de 40 núcleos en todas las ejecuciones. Se usaron todas las nubes de puntos descritas en el apartado 3.4, variando los siguientes hiperparámetros:

- **Modo de reordenamiento.** Se probaron tanto los dos modos implementados como la versión base secuencial, teniendo una comparación directa con el rendimiento anterior del programa.
- **Algoritmo de búsqueda.** Se sometieron a pruebas los dos métodos estudiados y modificados: *neighborsPrune* y *neighborsStruct*.

- **Kernel.** Los dos kernels en tres dimensiones soportados: cubo y esfera.
- **Algoritmos de SFC.** Se usaron tanto los códigos de Morton como los de Hilbert. Sin embargo, no se analizaron los resultados por separado, eso está fuera del alcance del trabajo. Se incluyeron para promediar los resultados con los dos *encoders* y tener una visión más contrastada de los resultados.
- **Radio.** Se dividieron las nubes en tres grupos: de densidad alta, media y baja, según la naturaleza de la nube. Para cada grupo se ejecutó una selección de 8 radios distintos adaptada a la cantidad de vecinos aproximada que producirán.
- **Tamaño de hoja (número máximo de puntos).** Este parámetro es de los más críticos para este trabajo. Puede influir directamente en el rendimiento temporal de la poda. Se probaron valores de 128, 256, 512, 1024
- **Umbral de poda (threshold).** Parámetro dedicado de esta optimización. Puede presentar cambios en el rendimiento, midiendo en qué punto deja de ser rentable o no el algoritmo de poda. Se probaron valores de 16, 64, 100

A continuación, se muestran los resultados obtenidos. Para empezar, se visualiza el tiempo de ejecución medio, dado un radio y una geometría de búsqueda, de cada combinación de algoritmo y reordenación local para diferentes tamaños de hoja. En las Figuras 5.1 y 5.2 se ven los resultados variando el radio y la nube de puntos usada.




Figura 5.1: Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios tomando diferentes radios en 5085_54320

5.2. RENDIMIENTO DE BÚSQUEDAS DE VECINOS PARALELAS CON CENTROS ALEATORIOS




Figura 5.2: Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios tomando diferentes radios en *bildstein_station1*

Tal y como se evidencia en las Figuras 5.1 y 5.2, los mínimos absolutos de tiempo se alcanzan de manera consistente al configurar un tamaño de nodo hoja fijado en 256. Asimismo, destaca la superioridad del algoritmo *neighborsStruct*. Aislando sus dos versiones, las implementaciones que incorporan reordenaciones locales y selectores de rango reportan una aceleración notable del tiempo de ejecución respecto al algoritmo original del Octree lineal, especialmente kernels esféricos. En cuanto a los resultados de *neighborsPrune*, en general están alejados, pero tanto el reordenamiento polar como el cartesiano tienen un desempeño similar, en casos superior, al algoritmo base. Comparándolos entre ellos, ninguno de los dos reordenamientos aplicados a *neighborsPrune* destaca enormemente sobre el otro. Una tendencia que sí se puede apreciar es que los reordenamientos mantienen el rendimiento de forma más estable a medida que se disparan los tamaños de las hojas, contrastando con la degradación en los tiempos que sufren las implementaciones originales.

Seguidamente, se analiza el impacto combinado de las dos variables de control críticas en el rendimiento de la poda: el tamaño máximo de nodo hoja (**maxLeaf**) frente al umbral de activación del selector (**threshold**). Para aislar el efecto del resto de parámetros, ambas variables se contraponen en una matriz bidimensional.

El valor indexado en cada celda de la matriz corresponde a la media aritmética del *speedup* (S) obtenido para el conjunto de radios evaluados. Para evitar que los radios con mayores tiempos absolutos sesguen el mapa de calor, el *speedup* de cada radio r se normaliza dividiendo el tiempo de la configuración actual entre el tiempo mínimo absoluto registrado para ese mismo radio entre todo el

espectro de hiperparámetros testados. Finalmente, este indicador se promedia combinando los resultados de ambos kernels de búsqueda (cubo y esfera), respondiendo a la siguiente expresión:

$$S_{\text{medio}} = \frac{1}{|K| \cdot |R|} \sum_{k \in K} \sum_{r \in R} \frac{T_{\text{optimo}}(k)}{T(k, r, \text{maxLeaf}, \text{threshold}, \text{algoritmo})} \quad (5.1)$$




Figura 5.3: Análisis del rendimiento temporal de hiperparámetros en las nubes de puntos *Mar18Train* y *Mar18Test*

Debido a que la reordenación polar en conjunto con las búsquedas mediante *neighborsStruct* fue la más eficiente, será esa configuración en la que se centrará el estudio de hiperparámetros. Como se puede apreciar en la Figura 5.3, la combinación más eficiente para el comportamiento del Octree en las nubes del dataset *Hessigheim 3D* se produce con hojas de 256 puntos y con un umbral de activación de poda (**threshold**) fijado en 16 puntos.

No obstante, distintas distribuciones de puntos en cada dataset provocan que las combinaciones óptimas presenten ligeras variaciones según la nube de puntos analizada. Por este motivo, se evaluó de forma independiente qué par de hiperparámetros favorecía el rendimiento de cada entorno específico.

Estas configuraciones óptimas personalizadas constituyen las bases de datos con las que se alimentaron los resultados a continuación expuestos. En dichos gráficos se cuantifica el tiempo medio de ejecución de las 10.000 consultas espaciales a medida que se incrementa el radio de búsqueda de forma continua, distribuyendo cada serie como una combinación única de algoritmo de asignación y modo de reordenamiento local. Se pueden ver los resultados para diferentes nubes de puntos en las Figuras (1) a (última) NO SE SI PONER TODAS LAS GRAFICAS AQUI O UNA SUPER TABLA O QUE.

5.3. RENDIMIENTO DE BÚSQUEDAS DE VECINOS PARALELAS SOBRE TODA LA NUBE33




Figura 5.4: Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios para diferentes radios en la nube *Mar18_Train*




Figura 5.5: Tiempos medios de búsqueda de vecindades de 10.000 puntos aleatorios para diferentes radios en la nube *Mar18_Test*

5.3. Rendimiento de búsquedas de vecinos paralelas sobre toda la nube

Estos experimentos tratan un caso de uso muy común en el manejo de nubes de puntos 3D, la búsqueda de vecinos a lo largo de todo el conjunto. Estos experimentos se pueden comportar de forma diferente a las búsquedas aleatorias debido a que, al realizar las búsquedas de forma secuencial y asignar a cada hilo un bloque de puntos consecutivos, es probable que muchos puntos compartan vecinos y por tanto habrá más aciertos caché. *A priori*, este factor no debería impactar tanto en el rendimiento de las reordenaciones locales, como lo hace al variar las implementaciones del Octree o las curvas de llenado utilizadas. Aún así, se puede presentar un comportamiento distinto y es interesante analizarlo. Debido a lo costosas que son estas ejecuciones, se seleccionaron un subconjunto de las nubes preparadas, manteniendo variedad entre LiDAR te-

restre y aéreo provenientes de diversos datasets. También se mantuvieron fijos los hiperparámetros de `maxLeaf` y `threshold`. Se escogió para cada conjunto de nubes un par de valores que fue exitoso para esa distribución de puntos en los experimentos de centros aleatorios:

- **Perfil de alta densidad:** Nube *bildstein_station1*. Configuración: [256, 64]
- **Perfil de densidad media:** Nubes *Mar18_train* y *Paris_Luxembourg_6*. Configuración: [128, 64]
- **Perfil de baja densidad:** Nubes *PNOA_2024_PNR_489-4672_NPC01* y *5085-54320*. Configuración: [256, 64]

Adicionalmente, se fijó el algoritmo SFC a los códigos de Hilbert y se fijó una única repetición de las búsquedas.

En la Figuras 5.6 a 5.8 se




Figura 5.6: Tiempos de ejecución de búsquedas completas variando el radio operativo sobre kernels esféricos y cúbicos para los datasets *5085_54320* (a) y *PNOA_2024_PNR_489-4672_NPC01* (b).

5.3. RENDIMIENTO DE BÚSQUEDAS DE VECINOS PARALELAS SOBRE TODA LA NUBE35




Figura 5.7: Tiempos de ejecución de búsquedas completas variando el radio operativo sobre kernels esféricos y cúbicos para los datasets *Mar18_train* (a) y *Paris_Luxembourg_6* (b).




Figura 5.8: Tiempos de ejecución de búsquedas completas variando el radio operativo sobre kernels esféricos y cúbicos para el dataset *bildstein_station1*.

Capítulo 6

Discusión de los resultados

Comprobación da(s) hipótese(s) de partida do traballo. Comparativa con algunha das solucións similares presentadas no estado de coñecemento, resaltando por que o traballo presentado mellora as solucións anteriores.

Capítulo 7

Exemplos (eliminar capítulo na versión final)

7.1. Un exemplo de sección

Esta é *letra cursiva*, esta é **letra negrilla**, esta é letra subrallada, e esta é **letra curier**. Letra tiny, scriptsize, small, large, Large, LARGE e moitas más. Exemplo de fórmula: $a = \int_0^\infty f(t)dt$. E agora unha ecuación aparte:

$$S = \sum_{i=0}^{N-1} a_i^2. \quad (7.1)$$

As ecuaciones se poden referenciar: ecuación (7.1).

7.1.1. Un exemplo de subsección

O texto vai aquí.

7.1.2. Outro exemplo de subsección

O texto vai aquí.

Un exemplo de subsubsección

O texto vai aquí.

Un exemplo de subsubsección

O texto vai aquí.

Un exemplo de subsubsección

O texto vai aquí.




Figura 7.1: Esta é a figura de tal e cal.

Izquierda	Derecha	Centrado
ll	r	cccc
llll	rrr	c

Cuadro 7.1: Esta é a táboa de tal e cal.

7.2. Exemplos de figuras e cadros

A figura número 7.1.
O cadro (taboa) número 7.1.

7.3. Exemplos de referencias á bibliografía

Este é un exemplo de referencia a un documento descargado da web [1]. E este é un exemplo de referencia a unha páxina da wikipedia [2]. Agora un libro [3] e agora unha referencia a un artigo dunha revista [4]. Tamén se poden por varias referencias á vez [1, 3].

7.4. Exemplos de enumeracións

Con puntos:

- Un.
- Dous.
- Tres.

Con números:

1. Catro.
2. Cinco.
3. Seis.

Exemplo de texto verbatim:

```
0 texto          verbatim
  se visualiza tal
    como se escribe
```

Exemplo de código C:

```
#include <math.h>
main()
{   int i, j, a[10];
    for(i=0;i<=10;i++) a[i]=i; // comentario 1
    if(a[1]==0) j=1; /* comentario 2 */
    else j=2;
}
```

Exemplo de código Java:

```
class HelloWorldApp {
    public static void main(String[] args) {
        System.out.println("Hello -World!"); // Display the string.
    }
}
```


Capítulo 8

Conclusións e posibles ampliacións

Resumo das principais aportacións do traballo, explicacións das suposicións e limitacións do traballo, e posibles vías de mellora.

Apéndice A

Manuais técnicos

En función do tipo de Traballo e metodoloxía empregada, o contido poderase dividir en varios documentos. En todo caso, neles incluírase toda a información precisa para aquelas persoas que desexen repetir o experimento (por exemplo código fonte, recursos necesarios, operacións necesarias para modificacións e probas, posibles problemas, etc.). O código fonte poderase entregar en soporte informático en formatos PDF ou postscript.

Apéndice B

Manuais de usuario

Incluirán toda a información precisa para aquelas persoas que repliquen o experimento: instalación, utilización, configuración, mensaxes de erro, etc. A documentación do usuario debe ser autocontida, é dicir, para o seu entendemento o usuario final non debe precisar da lectura doutro manual técnico.

Apéndice C

Licenza

Se se quere pór unha licenza (GNU GPL, Creative Commons, etc), o texto da licenza vai aquí.

Bibliografía

- [1] Nvidia CUDA programming guide. Versión 2.0, 2010. Disponible en <http://www.nvidia.com>.
- [2] Acceso múltiple por división de código. Artigo da wikipedia (<http://es.wikipedia.org>). Consultado o 2 de xaneiro do 2010.
- [3] R.C. Gonzalez e R.E. Woods, *Digital image processing*, 3ª edición, Prentice Hall, New York, 2007.
- [4] P. González, J.C. Cartex e T.F. Pellas, “Parallel computation of wavelet transforms using the lifting scheme”, *Journal of Supercomputing*, vol. 18, no. 4, pp. 141-152, junio 2001.